

Analisi temporale del vento solare

applicazione di modelli statistici (HMM e ARIMA)

alla previsione del vento solare

Alberto Prino

13 Febbraio 2026



Presentation Overview

- 1 Introduzione
- 2 HMM
- 3 ARIMA
- 4 Rolling ARIMA

Introduzione al dataset

Il dataset utilizzato in questo lavoro è derivato dalle osservazioni dello strumento *Solar Wind Ion Composition Spectrometer* (SWICS), a bordo della missione *Advanced Composition Explorer* (ACE) della NASA, che si occupa di misurare dati riguardanti il plasma del vento solare.

I dati sono campionati con una cadenza temporale di due ore e descrivono le proprietà di diverse specie ioniche: elio, carbonio, ossigeno e ferro.


Il dataset contiene 24924 entrate e 13 features.

Features del dataset


Tabella: Variabili del dataset SWICS/ACE e relative unità fisiche.

Variabile	Descrizione fisica	Unità
time	Tempo di osservazione	–
nHe2	Densità numerica degli ioni He ²⁺	cm ⁻³
vHe2	Velocità di flusso degli ioni He ²⁺	km s ⁻¹
vC5	Velocità di flusso degli ioni C ⁵⁺	km s ⁻¹
vO6	Velocità di flusso degli ioni O ⁶⁺	km s ⁻¹
vFe10	Velocità di flusso degli ioni Fe ¹⁰⁺	km s ⁻¹
HetoO	Rapporto di abbondanza He/O	–
CtoO	Rapporto di abbondanza C/O	–
FetoO	Rapporto di abbondanza Fe/O	–

Andamento delle velocità nel tempo



Andamento della densità di elio nel tempo



Analisi della composizione




Figura: Adattamento esponenziale della composizione in base alla massa.

Test goodness-of-fit



L'algoritmo adottato per verificare l'ipotesi di una dipendenza esponenziale della composizione del plasma dalla massa atomica delle specie ioniche può essere riassunto nei seguenti passaggi:

- ① Costruzione della distribuzione a posteriori delle abbondanze relative \mathbf{p} mediante un modello bayesiano Dirichlet, a partire dai conteggi osservati sommati sull'intero dataset.
- ② Calcolo del valore medio a posteriori $\langle \mathbf{p} \rangle$ delle abbondanze relative.
- ③ Definizione di un modello parametrico di composizione dipendente dalla massa atomica m_i ,

$$p_i^{\text{model}}(\lambda) = \frac{\exp(-\lambda m_i)}{\sum_j \exp(-\lambda m_j)}.$$

- ④ Stima del parametro λ tramite minimizzazione numerica

Andamento energia media nel tempo



Teoria degli HMM

Un HMM è definito da:

- una sequenza di stati latenti discreti $z_t \in \{1, \dots, K\}$,
- una matrice di transizione \mathbf{P} , con

$$\pi_{ij} = p(z_{t+1} = j \mid z_t = i),$$

- una distribuzione di emissione
 $p(x_t \mid z_t = k) = \mathcal{N}(x_t \mid \mu_k, \sigma_k)$ (HMM gaussiano).

Algoritmo Baum-Welch

- Come prior sulle probabilità di transizione si assume una Dirichlet: $\pi_{z_0, k} \sim Dir(\alpha_0)$, con $\alpha_0 = (1, 1)$.
- Prior sulle righe della matrice di transizione: $\pi_k \sim Dir(\alpha)$, $\alpha = (1, 1)$.
- Prior normale sulla media delle distribuzioni di emissione: $\mu_k = \mathcal{N}(0, \frac{1}{w}\sigma_k^2)$.
- Prior sulle varianze: $\sigma_k^2 = IG(1, 0.01)$ (Gamma inversa).

Poiché il parametro default di w è 0, la prior non ha alcuna influenza e la media viene stimata dal modello basandosi sui dati osservati. La media viene attraverso il metodo MAP:

$$\mu_k = \frac{w \cdot \mu_{prior} + \sum_t \gamma_k(t)x_t}{w + \sum_t \gamma_k(t)} = \frac{\sum_t \gamma_k(t)x_t}{\sum_t \gamma_k(t)}.$$

Passo E

Passo forward: sia $\alpha_t(i) = p(x_1, \dots, x_t, z_t = k | \theta)$, la probabilità di osservare x_1, \dots, x_t ed essere allo stato k al tempo t . Si calcola ricorsivamente.

Inizializzazione:

$$\alpha_1(i) = \pi_i \cdot p(x_1 | z_1 = i) = \pi_i \cdot \mathcal{N}(x_1; \mu_i, \Sigma_i).$$

Ricorsione:

$$\alpha_{t+1}(j) = \left[\sum_{i=1}^N \alpha_t(i) \pi_{ij} \right] \cdot \mathcal{N}(x_{t+1}; \mu_j, \Sigma_j).$$

Passo backward: sia $\beta_t(i) = p(x_{t+1}, \dots, x_T | z_t = k, \theta)$ la probabilità di osservare x_{t+1}, \dots, x_T sapendo che al tempo t il processo è allo stato k . Si calcola ricorsivamente.

Inizializzazione:

$$\beta_T(i) = 1.$$

Ricorsione:

$$\beta_t(i) = \sum_{j=1}^N \pi_{ij} \cdot \mathcal{N}(x_{t+1}; \mu_j, \Sigma_j) \cdot \beta_{t+1}(j).$$

Calcolo delle probabilità derivate:

Probabilità dello stato:

$$\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{\sum_{j=1}^N \alpha_t(j)\beta_t(j)}.$$

Probabilità di transizione:

$$\xi_t(i,j) = P(z_t = i, z_{t+1} = j \mid \mathbf{x}_{1:T}, \theta^{(n)}) = \frac{\alpha_t(i)\pi_{ij}\mathcal{N}(x_{t+1}; \mu_j, \sigma_j)\beta_{t+1}(j)}{\sum_{k=1}^N \sum_{m=1}^N \alpha_t(k)\pi_{km}\mathcal{N}(x_{t+1}; \mu_m, \Sigma_m)\beta_{t+1}(m)}.$$

Passo M

I parametri del modello vengono aggiornati per massimizzare la likelihood:

$$\pi_{z_0, k}^{(n+1)} = \gamma_1(k),$$

$$\pi_{ij}^{(n+1)} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)},$$

$$\mu_k^{(n+1)} = \frac{\sum_{t=1}^T \gamma_t(k) x_t}{\sum_{t=1}^T \gamma_t(k)},$$

$$\sigma_k^{(n+1)} = \frac{\sum_{t=1}^T \gamma_t(k) (x_t - \mu_k)(x_t - \mu_k)^\top}{\sum_{t=1}^T \gamma_t(k)}.$$

Algoritmo Viterbi

La previsione sugli stati z_t viene ottenuta con l'algoritmo di Viterbi, che calcola la singola sequenza più probabile di stati latenti nel senso della massima probabilità a posteriori (MAP):

$$\hat{z}_{1:T} = \arg \max_{z_{1:T}} P(z_{1:T} | x_{1:T}).$$

Applicazione al dataset



Il modello è stato prima addestrato su tutto il dataset per osservare le energie medie associate agli stati, con $K = 2$.

Stato	μ [eV]
0	2918.8
1	6780.2

Matrice di transizione stimata

$$\mathbf{P} = \begin{pmatrix} 0.983 & 0.017 \\ 0.023 & 0.977 \end{pmatrix}.$$

Visualizzazione della classificazione



Testing HMM

Il modello è stato allenato sul primo 80% dei dati e testato sul restante 20%, coi seguenti risultati:

- Durate medie:

$$\langle D_0 \rangle \approx 59, \quad \langle D_1 \rangle \approx 44.$$

- Predictive log-score medio: -9.65.
- Errore assoluto medio (MAE):

$$\text{MAE}_{\text{baseline}} = 214 \text{ eV}, \quad \text{MAE}_{\text{HMM}} = 997 \text{ eV}.$$

Visualizzazione delle predizioni




Figura: Previsione di regime sul test split del dataset.

Definizione del modello

Un modello ARIMA(p, d, q) applicato al processo gaussiano x_t può essere espresso come:

$$\phi(B)(1 - B)^d x_t = \theta(B) \omega_t.$$

Dove:

- B è l'operatore di ritardo ($Bx_t = x_{t-1}$);
- p è l'ordine autoregressivo ($AR(p)$);
- d è il grado di differenziazione ($I(d)$);
- q è l'ordine della media mobile ($MA(q)$);
- ω_t è un rumore bianco con media nulla e varianza costante, non necessariamente gaussiano;
- $\phi(B)$ e $\theta(B)$ sono polinomi in B .

Fallimento approccio ARIMA classico




Figura: ARIMA con parametri (2,0,2)

Ricerca di d

Viene fatta attraverso i test ADF (H_0 : serie non stazionaria) e KPSS (H_0 : serie stazionaria).

Tabella: Risultati dei test di stazionarietà ADF e KPSS

Serie	Test	p-value	Conclusione
$d = 0$	ADF	$< 1e-04$	Rifiuto H_0
	KPSS	0.0100	Rifiuto H_0
$d = 1$	ADF	$< 1e-04$	Rifiuto H_0
	KPSS	0.1000	Non rifiuto H_0

Ricerca di p e q

Per restringere il campo di ricerca di p e q , si è valutato il plot di ACF e PACF per la serie differenziata.




Figura: ACF e PACF della serie differenziata.

Forecasting

Dalla gridsearch emerge che la combinazione migliore è (1,1,2), che fornisce i seguenti risultati:




Figura: Rolling ARIMA con parametri (1,1,2)

Fine